



SISTEMA RECOMENDADOR DE REVISTAS CIENTÍFICAS

AUTOR: SANTIAGO SANTANA MARTÍNEZ

ASIGNATURA: CIENCIA DE DATOS EN INGENIERÍA

MOTIVACIÓN

Existen miles de revistas científicas

En un mismo campo
→ decenas de opciones

Elegir revista correcta:

Problema:


Aumenta visibilidad

Incrementa probabilidad de aceptación

Mucho de donde elegir, decisión basada en experiencia subjetiva.

OBJETIVO DEL TRABAJO

- Desarrollar un **sistema inteligente** que:
 - Reciba como entrada:
 - Título
 - Resumen
 - Palabras clave
 - recomiende automáticamente:
 - La revista más adecuada



El sistema aprende a partir de artículos previamente publicados entre los años 2020 y 2024.

ENFOQUES PLANTEADOS


Se exploran dos aproximaciones:

- **Aproximación clásica**

- TF-IDF
- Modelos de clasificación tradicionales
- Scikit-learn


- **Aproximación conexionista**

- Word embeddings
- Redes neuronales recurrentes
- PyTorch + GPU (CUDA)




CONJUNTO DE DATOS

- Artículos científicos de:
 - Expert Systems with Applications (ESA)
 - Pattern Recognition (PR)
 - Neural Networks (NN)
 - Pattern Recognition Letters (PRL)
 - Robotics and Autonomous Systems (RAS)
- Información textual:
 - Título
 - Abstract
 - Keywords
- Etiqueta:
 - Revista de publicación
- **Problema detectado:**
 - Fuerte desbalance entre revistas



FILTRADO DEL DATASET

- Decisión tomada:
 - Eliminar revistas con **menos de 20 artículos**
- Motivación:
 - Evitar ruido estadístico
 - Evaluaciones más estables
 - Sin rebalanceo artificial
- Resultado:
 - Dataset más compacto y representativo



PREPROCESAMIENTO DEL TEXTO


- Operaciones comunes:

- Minúsculas
- Eliminación de símbolos
- Eliminación de stopwords
- Tokenización

- Variantes evaluadas:

- TF-IDF estándar
- TF-IDF + lematización (NLTK)

Hipótesis: la lematización podría mejorar generalización



APROXIMACIÓN CLÁSICA

ENTRADA: TEXTO → TF-IDF → REPRESENTACIONES NUMÉRICAS

ENTRADA (CON LEMATIZACIÓN): TEXTO → TF-IDF → LEMATIZACIÓN → REPRESENTACIONES NUMÉRICAS

ENTRENAMIENTO DE MODELOS CLÁSICOS: LOGISTIC REGRESSION, LINEAR SVC Y RANDOM FOREST

APROXIMACIÓN CLÁSICA: REPRESENTACIÓN

TF-IDF (Term Frequency – Inverse Document Frequency)

- Representa cada documento como un vector de pesos asociados a términos
- Penaliza palabras muy frecuentes en el corpus (*model, data*)
- Resalta términos con alto poder discriminativo entre revistas

N-gramas

- Unigramas: (*neural, network, learning, vision*)
- Bigramas: (*neural network, computer vision, pattern recognition*)
- Mejoran la capacidad del modelo para distinguir dominios científicos cercanos

Representación resultante


- Espacio vectorial de alta dimensión
- Matriz muy dispersa (sparse)
- Adecuada para modelos lineales como SVM o Regresión Logística

Ventaja

Representación simple, eficiente y altamente informativa para clasificación de texto

APROXIMACIÓN CLÁSICA: MODELOS

- Modelos entrenados:
 - Logistic Regression
 - Linear SVC
 - Random Forest
- Cada uno evaluado:
 - Con lematización
 - Sin lematización
- Evaluación:
 - Validación cruzada estratificada (CV)
 - Test independiente



APROXIMACIÓN CLÁSICA: MODELOS (CONFIGURACIÓN)

Logistic Regression	<code>max_iter=1000</code> <code>class_weight="balanced"</code> <code>n_jobs=-1</code>
Linear SVC	<code>class_weight="balanced"</code>
Random Forest	<code>n_estimators=300</code> <code>random_state=42</code> <code>class_weight="balanced"</code> <code>n_jobs=-1</code>

APROXIMACIÓN CLÁSICA: RESULTADOS VALIDACIÓN CRUZADA

===== Logistic Regression + TF-IDF (Cross-Validation) =====

accuracy: 0.6789 ± 0.0096
precision: 0.5808 ± 0.0070
recall: 0.6384 ± 0.0107
f1: 0.6035 ± 0.0088

===== Linear SVM + TF-IDF (Cross-Validation) =====

accuracy: 0.7124 ± 0.0118
precision: 0.6097 ± 0.0125
recall: 0.6080 ± 0.0098
f1: 0.6063 ± 0.0113

===== Random Forest + TF-IDF (Cross-Validation) =====

accuracy: 0.6857 ± 0.0057
precision: 0.6842 ± 0.0189
recall: 0.4711 ± 0.0085
f1: 0.5069 ± 0.0097

===== Logistic Regression + Lemmatization (Cross-Validation) =====

accuracy: 0.6761 ± 0.0091
precision: 0.5775 ± 0.0078
recall: 0.6352 ± 0.0101
f1: 0.6002 ± 0.0089

===== Linear SVM + Lemmatization (Cross-Validation) =====

accuracy: 0.7085 ± 0.0109
precision: 0.6040 ± 0.0112
recall: 0.6013 ± 0.0126
f1: 0.6000 ± 0.0120

===== Random Forest + Lemmatization (Cross-Validation) =====

accuracy: 0.6821 ± 0.0048
precision: 0.6979 ± 0.0198
recall: 0.4599 ± 0.0069
f1: 0.4949 ± 0.0074

APROXIMACIÓN CLÁSICA: RESULTADOS (TEST)

==== Logistic Regression (TF-IDF) - Test ====

Accuracy: 0.6845618915159944

Classification Report:

	precision	recall	f1-score	support
ESA	0.90	0.75	0.82	2047
NN	0.57	0.65	0.61	480
PR	0.49	0.61	0.54	585
PRL	0.28	0.37	0.32	315
RAS	0.70	0.85	0.77	168
accuracy			0.68	3595
macro avg	0.59	0.64	0.61	3595
weighted avg	0.72	0.68	0.70	3595

==== Linear SVM (TF-IDF) - Test ====

Accuracy: 0.7159944367176634

Classification Report:

	precision	recall	f1-score	support
ESA	0.86	0.85	0.85	2047
NN	0.59	0.58	0.59	480
PR	0.51	0.59	0.55	585
PRL	0.34	0.27	0.30	315
RAS	0.76	0.81	0.78	168
accuracy			0.72	3595
macro avg	0.61	0.62	0.61	3595
weighted avg	0.71	0.72	0.71	3595

==== Random Forest (TF-IDF) - Test ====

Accuracy: 0.6812239221140473

Classification Report:

	precision	recall	f1-score	support
ESA	0.69	0.94	0.80	2047
NN	0.86	0.34	0.48	480
PR	0.52	0.44	0.47	585
PRL	0.65	0.05	0.09	315
RAS	0.78	0.55	0.64	168
accuracy			0.68	3595
macro avg	0.70	0.46	0.50	3595
weighted avg	0.69	0.68	0.63	3595

==== Logistic Regression (Lemmatization) - Test ====

Accuracy: 0.6828929068150209

Classification Report:

	precision	recall	f1-score	support
ESA	0.90	0.75	0.82	2047
NN	0.55	0.64	0.60	480
PR	0.48	0.62	0.54	585
PRL	0.29	0.35	0.31	315
RAS	0.70	0.85	0.77	168
accuracy			0.68	3595
macro avg	0.58	0.64	0.61	3595
weighted avg	0.72	0.68	0.70	3595

==== Linear SVM (Lemmatization) - Test ====

Accuracy: 0.7112656467315717

Classification Report:

	precision	recall	f1-score	support
ESA	0.85	0.84	0.84	2047
NN	0.59	0.56	0.58	480
PR	0.51	0.59	0.55	585
PRL	0.33	0.25	0.28	315
RAS	0.76	0.82	0.79	168
accuracy			0.71	3595
macro avg	0.61	0.61	0.61	3595
weighted avg	0.71	0.71	0.71	3595

==== Random Forest (Lemmatization) - Test ====

Accuracy: 0.678442280945758

Classification Report:

	precision	recall	f1-score	support
ESA	0.69	0.94	0.80	2047
NN	0.89	0.33	0.48	480
PR	0.50	0.44	0.47	585
PRL	0.69	0.03	0.07	315
RAS	0.81	0.50	0.62	168
accuracy			0.68	3595
macro avg	0.72	0.45	0.49	3595
weighted avg	0.69	0.68	0.63	3595

APROXIMACIÓN CLÁSICA: DECISIÓN

- Linear SVM obtiene mejor rendimiento medio
- Resultados estables
- Lematización: impacto nulo o negativo

```
===== Logistic Regression + TF-IDF (Cross-Validation) =====  
accuracy: 0.6789 ± 0.0096  
precision: 0.5808 ± 0.0070  
recall: 0.6384 ± 0.0107  
f1: 0.6035 ± 0.0088
```

```
===== Linear SVM + TF-IDF (Cross-Validation) =====  
accuracy: 0.7124 ± 0.0118  
precision: 0.6097 ± 0.0125  
recall: 0.6080 ± 0.0098  
f1: 0.6063 ± 0.0113
```

```
===== Random Forest + TF-IDF (Cross-Validation) =====  
accuracy: 0.6857 ± 0.0057  
precision: 0.6842 ± 0.0189  
recall: 0.4711 ± 0.0085  
f1: 0.5069 ± 0.0097
```



```
===== Linear SVM (TF-IDF) - Test =====
```

Accuracy: 0.7159944367176634

Classification Report:

	precision	recall	f1-score	support
ESA	0.86	0.85	0.85	2047
NN	0.59	0.58	0.59	480
PR	0.51	0.59	0.55	585
PRL	0.34	0.27	0.30	315
RAS	0.76	0.81	0.78	168
accuracy			0.72	3595
macro avg	0.61	0.62	0.61	3595
weighted avg	0.71	0.72	0.71	3595

APROXIMACIÓN CLÁSICA : MATRICES DE CONFUSIÓN (SVM)



APROXIMACIÓN CLÁSICA: CONCLUSIONES

TF-IDF

- Representación suficientemente buena

Lematización

- Para este caso concreto, no parece aportar mejoras

Regresión Logística + TF-IDF

- Rendimiento estable ($\approx 68\%$ accuracy)
- Buen compromiso simplicidad–resultado
- Limitada para separar clases semánticamente cercanas

Random Forest + TF-IDF

- Buen rendimiento en clases mayoritarias
- Bajo *recall* en revistas minoritarias
- Sesgo claro debido a alta dimensionalidad y sparsity

Linear SVC + TF-IDF

- Mejor rendimiento global ($\approx 71\text{--}72\%$ accuracy)
- Mayor estabilidad entre validación cruzada y test
- Mejor separación entre revistas similares

Conclusión

Linear SVC + TF-IDF es el modelo clásico ganador, ofreciendo el mejor equilibrio entre rendimiento, estabilidad y coste computacional.

APROXIMACIÓN CONEXIONISTA

ENTRADA: TEXTO → TOKENIZACIÓN → TOKENS → WORD2VEC → SECUENCIAS NUMÉRICAS

ARQUITECTURA: EMBEDDINGS → LSTM → CAPA DE CLASIFICACIÓN

ENTRENADO EN PYTORCH CON CUDA 13.1

APROXIMACIÓN CONEXIONISTA: REPRESENTACIÓN

Dataset empleado

- Mismo dataset que el usado en los modelos clásicos
- División del conjunto en 80% entrenamiento y 20% validación

Tokenización simple

- Conversión del texto a minúsculas
- Eliminación de signos de puntuación y caracteres especiales
- Separación del texto en secuencias de palabras

Word2Vec

- Entrenamiento sobre el corpus de artículos
- Esquema *Skip-gram* para capturar relaciones semánticas locales
- Aprende representaciones vectoriales de las palabras


Construcción de la matriz de embeddings

- Cada palabra se representa como un vector numérico
- Se genera una matriz vocabulario $\times$ dimensión
- Esta matriz inicializa la capa de embeddings del modelo neuronal

Resultado

- Representación distribuida del texto
- Entrada semántica para el modelo BiLSTM



APROXIMACIÓN CONEXIONISTA: ARQUITECTURA (BILSTM)



APROXIMACIÓN CONEXIONISTA: CONFIGURACIÓN DE LA RED

Categoría	Tipo de Parámetro	Valor
Representación	Embedding	Word2Vec
	Dimensión de Embedding	100
Entrada	Longitud Máxima	300 tokens
Arquitectura	Tipo de Red	LSTM
	Dimensión Oculta	64
	Direccionalidad	Bidireccional
Regularización	Dropout	0,5
	Weight Decay (L2)	10^{-5}
Entrenamiento	Función de Pérdida	Cross-Entropy
	Optimizador	Adam
	Batch Size	32
	Épocas Máximas	100
	Early Stopping	Sí (patience = 10)

APROXIMACIÓN CONEXIONISTA: EVOLUCIÓN DEL ENTRENAMIENTO



APROXIMACIÓN CONEXIONISTA: RESULTADOS EVALUACIÓN FINAL


- Accuracy test $\approx 71\%$
- Comparable a modelos clásicos
- Tendencia clara al sobreajuste

Final Test Accuracy: 0.7051460361613352

	precision	recall	f1-score	support
ESA	0.79	0.89	0.83	2047
NN	0.64	0.49	0.56	480
PR	0.49	0.60	0.54	585
PRL	0.43	0.09	0.15	315
RAS	0.78	0.64	0.70	168
accuracy			0.71	3595
macro avg	0.63	0.54	0.56	3595
weighted avg	0.69	0.71	0.68	3595

APROXIMACIÓN CONEXIONISTA: MATRIZ DE CONFUSIÓN

- Expert Systems with Applications → 0
- Neural Networks → 1
- Pattern Recognition → 2
- Pattern Recognition Letters → 3
- Robotic Autonomous Systems → 4



APROXIMACIÓN CONEXIONISTA: CONCLUSIONES

Modelo BiLSTM + Word2Vec

- Capaz de capturar orden y contexto semántico del texto
- Representación distribuida aprendida específicamente del dominio
- Rendimiento competitivo: $\approx 71\%$ accuracy

Regularización

- Dropout, weight decay y early stopping necesarios
- Evidente tendencia al sobreajuste sin regularización
- Entrenamiento sensible a hiperparámetros

Comparación con modelos clásicos

- No supera claramente a Linear SVM + TF-IDF
- Mayor coste computacional y complejidad
- Ventaja potencial con mayor volumen de datos

Conclusión

En este escenario, la aproximación conexionista parece viable, pero los métodos clásicos siguen siendo más eficientes y estables.

CONCLUSIONES FINALES

- Se ha desarrollado un sistema de recomendación de revistas científicas a partir del contenido textual de los artículos.
- Se han comparado dos enfoques: aproximación clásica (TF-IDF + clasificadores) y aproximación conexionista (BiLSTM + Word2Vec).
- Linear SVM + TF-IDF obtiene el mejor rendimiento global ($\approx 72\%$ accuracy), mostrando gran estabilidad y bajo coste computacional.
- La aproximación conexionista parece viable ($\approx 71\%$), pero presenta mayor complejidad y tendencia al sobreajuste con el tamaño de datos disponible.
- Los errores se concentran en revistas con dominios temáticos cercanos, lo cual es coherente semánticamente.
- En conjuntos de datos moderados, los métodos clásicos siguen siendo la opción más eficiente; los modelos neuronales resultan prometedores en escenarios con mayor volumen y diversidad de datos.

REFERENCIAS

- Fuente del dataset
 - [SinceDirect](#)
- Documentación
 - [Logistic Regression](#)
 - [Linear SVC](#)
 - [Random Forest](#)
 - Apuntes del campus virtual de la ULPGC – Asignatura Ciencia de datos en Ingeniería